

期末考查报告

姓 名：_____

学 号：_____

学 院：信息工程学院

专 业：软件技术

年 级：_____

班 级：_____

指导教师：_____

2026年6月8日至 2026年6月26日

所在 单 位：_____ 级 _____ 学 院 _____ 专 业 _____ 班

项目名称：药品销售数据处理与分析

项目目的：

1. 掌握使用 Pandas 读取本地 Excel 数据的方法。
2. 能够查看数据结构、字段类型、缺失值和重复值情况。
3. 能够对销售时间、销售数量、应收金额和实收金额等字段进行规范化处理。
4. 能够识别并处理缺失值、无效日期、负数销售等异常数据。
5. 能够使用分组聚合完成月度、星期、商品维度的销售统计。
6. 能够使用 Matplotlib/Seaborn 生成可读的分析图表。
7. 能够将分析过程、结果和代码思路整理成报告和答辩材料。

项目内容及要求：

利用 Python (Pandas、NumPy、Matplotlib、Seaborn) 完成药品销售数据的加载、处理与分析，覆盖评分标准中的数据加载、数据概览、数据分析和数据可视化各项要求，并形成可用于答辩的报告与图表。

项目过程（按评分标准逐项说明）：

下面对照《评分标准》逐项说明，每一项给出评分要求、实现方式和运行结果。

（一）数据加载（5 分）

评分要求：采用合适的方法把本地文件中的数据加载至 Python 环境。

实现方式：data_loading.py 的 load_sales_data() 使用 pandas.read_excel() 读取 exam-materials/data/药品销售数据.xlsx，并在加载后校验必要字段是否齐全，文件或字段缺失时直接抛出清晰错误。

运行结果：成功读取原始数据 6578 行、8 列。

（二）数据概览（5 分）

1. 正确查看数据基本信息（3 分）

评分要求：正确查看数据基本信息。

实现方式：data_overview.py 的 inspect_raw_data() 输出行列数、字段列表、字段类型、缺失值数量和重复值数量。

运行结果：确认数据规模为 6578 行 × 8 列，原始重复行数量为 0；购药时间、社保卡号、星期各缺失 2 条，其余关键字段各缺失 1 条。

2. 修正列名（2 分）

评分要求：修正列名。

实现方式：data_overview.py 的 rename_sales_time() 将原始列名“购药时间”修正为“销售时间”，并保留“源数据行号”便于在异常记录表中追溯原始 Excel 行。

运行结果：列名由“购药时间”统一为“销售时间”，后续时间相关处理均基于该列。

(三) 数据处理 (30 分)

1. 重复值处理 (5 分)

评分要求：重复值处理。

实现方式：data_cleaning.py 基于销售时间、社保卡号、商品编码、商品名称、销售数量、应收金额、实收金额、星期这一组业务字段检测并删除重复记录。

运行结果：本次数据中重复记录为 0 行，无需删除。

2. 缺失值处理 (5 分)

评分要求：缺失值处理。

实现方式：对分析必需字段（销售时间、商品名称、销售数量、应收金额、实收金额）缺失的记录予以剔除；对不影响销售统计的社保卡号缺失记录，用“未知社保卡”标记保留。

运行结果：必需字段缺失的记录被剔除（计入异常值处理的剔除总量），社保卡号缺失的记录保留并标记。

3. 异常值处理 (20 分)

本项 20 分由四个子项构成：销售数据类型统一为整型（5 分）、销售时间类型统一为 DateTime 类型（5 分）、检测异常值（5 分）、处理异常值（5 分）。其中两项类型统一是异常值检测的前置步骤——只有先把字段转为正确类型，才能准确判断数量/金额是否为非正值、日期是否有效。

(1) 销售数据类型统一为整型 (5 分)

评分要求：销售数据类型统一为整型。

实现方式：data_cleaning.py 将销售数量转换为整型，应收金额、实收金额转换为数值类型，保证金额可参与求和与均值计算。

运行结果：销售数量统一为整型，金额字段统一为数值类型。

(2) 销售时间类型统一为 DateTime 类型 (5 分)

评分要求：销售时间类型统一为 DateTime 类型。

实现方式：data_cleaning.py 使用 pandas.to_datetime() 将销售时间转换为 DateTime 类型；星期不直接采用原始列，而是根据标准化后的销售时间重新计算，避免 2022-02-29 这类错误星期值影响统计。

运行结果：销售时间统一为 DateTime 类型，无效日期可被识别；星期由销售时间重算。

(3) 检测异常值 (5 分)

评分要求：检测异常值。

实现方式：分两类检测：确定错误（无效日期、关键字段缺失、销售数量或金额小于等于 0）；统计异常（使用 IQR 四分位距方法标记大额或大数量记录）。

运行结果：IQR 统计异常共标记 2012 条，已输出到 generated/tables/anomaly_rows.csv 供复核。

(4) 处理异常值 (5 分)

评分要求：处理异常值。

实现方式：确定错误记录予以剔除；IQR 统计异常的大额/大数量记录保留复核，因为医药销售中可能存在真实批量购买，不能只因数值大就删除。

运行结果：最终剔除确定错误记录 68 行，清洗后保留 6510 行有效数据；统计异常的 2012 条不直接删除，而是输出异常表供复核。

(四) 数据分析 (30 分)

1. 将数据按销售时间排序并重置行索引 (5 分)

评分要求：将数据按照销售时间进行排序，排序之后重置行索引。

实现方式：data_cleaning.py 将清洗后的数据按销售时间从小到大排序，并重置行索引 (reset_index)。

运行结果：数据按销售时间升序排列、行索引连续，分析时间范围为 2022-01-01 至 2022-07-19。

2. 计算月均销售金额 (5 分)

评分要求：计算月均销售金额。

实现方式：monthly_sales.py 按月份对实收金额进行分组聚合，并计算月均实收金额。

运行结果：各月份销售统计如下表，月均实收金额为 43434.98 元，其中 2022-01 的实收金额最高，为 49461.19 元。

月份	订单数	销售数量	实收金额
2022-01	1055	2527	49461.19
2022-02	742	1858	38790.38
2022-03	990	2225	41597.51
2022-04	1235	3012	48822.56
2022-05	952	2225	46925.27
2022-06	909	2328	48327.70
2022-07	627	1483	30120.22

3. 绘制销售时间与实收金额的关系 (5 分)


评分要求：绘制销售时间与实收金额的关系。

实现方式：time_actual_relationship.py 汇总每日实收金额并生成销售时间与实收金

额关系图。

运行结果：每日实收金额波动明显，部分日期存在高峰；高峰通常与大额或批量购药记录有关，因此在清洗中作为统计异常保留复核，未直接删除。

图 1 销售时间与每日实收金额关系



4. 根据星期分组统计销售数量、应收和实收金额（5 分）


评分要求：根据星期分组，统计每星期销售数量、应收和实收金额的关系。

实现方式：weekday_sales.py 按星期（由销售时间重算）分组，统计订单数、销售数量、应收金额和实收金额，并生成星期统计图。

运行结果：各星期销售统计如下表，星期五的订单数、销售数量、应收金额和实收金额均较高，是一周中销售表现最突出的日期。

星期	订单数	销售数量	应收金额	实收金额
星期一	778	1847	41265.10	38123.47
星期二	976	2315	45814.40	41934.47
星期三	961	2373	49218.30	45466.81
星期四	692	1718	37885.30	35187.31
星期五	1160	2831	56446.30	51284.66
星期六	1028	2472	53786.70	48510.65
星期日	915	2102	46960.00	43537.46

图 2 星期分组销售统计



5. 销售数量前十位药品 (10 分)

评分要求：根据商品名称分组，统计销售数量前十位的药品，绘制销售数量前十位的药品名称的销售数量关系。


实现方式：top_products.py 按商品名称分组统计销售数量，取前十位药品并生成 Top 10 图表。

运行结果：销售数量前十位药品如下表，销售数量最高的是 苯磺酸氨氯地平片(安内真) (销售数量 1781) ；不同药品的价格差异会影响实收金额排名。

排名	商品名称	订单数	销售数量	实收金额
1	苯磺酸氨氯地平片(安内真)	892	1781	19081.44
2	开博通	615	1440	37080.36
3	酒石酸美托洛尔片(倍他乐克)	548	1140	7919.82
4	硝苯地平片(心痛定)	420	825	1108.99
5	苯磺酸氨氯地平片(络活喜)	318	796	24251.04
6	复方利血平片(复方降压片)	304	515	1397.38
7	G 琥珀酸美托洛尔缓释片(倍他乐克)	195	509	8620.96
8	缬沙坦胶囊(代文)	143	445	16774.77

9	非洛地平缓释片 (波依定)	154	375	10419.56
10	高特灵	124	373	1997.95

图 3 销售数量前十位药品



(五) 项目汇报 (30 分)

评分要求：根据程序实施的思路完成对项目的汇报，每人汇报 3 分钟，内容主要包括代码完成思路及相关技术的应用和实现。

实现方式：汇报材料整理为 答辩.md（3 分钟口头汇报稿）、docs/defense-outline.md（答辩提纲）和 docs/defense-qa.md（预设问答）。

汇报主线：按“数据加载 → 数据概览与列名修正 → 数据处理（重复值、缺失值、类型统一、异常值检测与处理）→ 数据分析（排序、月均、时间关系、星期分组、Top 10）→ 可视化”讲解；技术上重点说明 Pandas 的 read_excel/to_datetime/分组聚合、NumPy 的 IQR 计算、Matplotlib/Seaborn 的中文图表配置，其中异常值处理策略是讲解重点。

评分点对照总览表：

评分项	分值	对应实现（模块/文件）	报告位置
数据加载	5	data_loading.py load_sales_data()	(一)
数据概览 — 正确查看 数据基本信息	3	data_overview.py inspect_raw_data()	(二) 1
数据概览 — 修正列名	2	data_overview.py	(二) 2

		rename_sales_time()	
数据处理 — 重复值处理	5	data_cleaning.py	(三) 1
数据处理 — 缺失值处理	5	data_cleaning.py	(三) 2
异常值处理 — 销售数据类型统一为整型	5	data_cleaning.py	(三) 3(1)
异常值处理 — 销售时间统一为 DateTime	5	data_cleaning.py	(三) 3(2)
异常值处理 — 检测异常值	5	data_cleaning.py (IQR)	(三) 3(3)
异常值处理 — 处理异常值	5	data_cleaning.py	(三) 3(4)
数据分析 — 按销售时间排序并重置索引	5	data_cleaning.py	(四) 1
数据分析 — 计算月均销售金额	5	monthly_sales.py	(四) 2
数据分析 — 销售时间与实收金额关系	5	time_actual_relationship.py	(四) 3
数据分析 — 星期分组统计	5	weekday_sales.py	(四) 4
数据分析 — 销售数量前十位药品	10	top_products.py	(四) 5
项目汇报	30	答 辩 .md 、 docs/defense-outline.md 、 docs/defense-qa.md	(五)
总分	100	—	—

个人总结：

通过本次项目，我完整实践了从数据读取、数据概览、数据清洗、异常处理、分组统计到图表生成的分析流程。项目中最需要注意的是异常值处理不能简单“一删了之”：负数销售、无效日期和关键字段缺失属于确定错误，应当剔除；但大额销售或大数量销售可能是真实业务现象，因此更适合作为统计异常保留复核。

本项目最终形成了可运行代码、清洗数据、统计表、图表、报告和答辩文档，能够逐项对应《Python 数据收集与分析》期末考查的评分标准。

学生签名：

指导教师签字（签章）：

曾思敏